

基于语料分析方法的生成式 AI 产品评测

以雅思写作反馈场景为例

产品分析报告

作者：王语晗

日期：2025 年 12 月 30 日

一、项目背景与目标

1.1 项目背景

市面上的雅思机构或个人雅思老师价格较高，大部分雅思考生为了节省成本而选择自学。学习雅思作文时，学生也都想让老师一对一修改每一篇练习文章，但这不仅价格高，而且老师在需要授课的前提下也不一定有空。相比之下，使用 AI 批改不仅兼具专业性和详尽的提升建议，而且价格相对便宜（只需要开一个月会员）甚至免费。

对于英语作文批改，英语母语的 AI 大模型当然是首选，但部分考生不会使用 VPN 或懒得使用，于是借助国产大模型提升作文。不过，国产大模型在英语教学反馈场景中的能力尚未被系统评估，各模型在批改雅思作文方面各有优劣，但没有量化对比和细致分析，学生往往不知道哪种模型适合雅思作文批改领域，也不知道哪种模型适合自己。因此，本测评从第二语言习得理论出发，结合人工评估和语料库分析方法，评估现有主流国内大模型在英语写作批改领域的优劣，并提出产品改进方案。

国产大模型如何补齐英语等其他语言领域的短板，是走向国际化的重要一步。从雅思作文批改这一垂直场景，可以窥见国产大模型在国际化运营和教育应用方面的发展方向。

1.2 评测目标

以三款国产模型（DeepSeek、豆包、通义千问）为主要分析对象；以三款英文模型（ChatGPT、Claude、Gemini）为行业参照组；以雅思考官反馈为金标准基准线。基于以上分析，最终产出国产模型写作反馈功能的现存问题与优化方案。

1.3 目标用户

雅思备考学生中，最需要 AI 辅助提升写作能力的是基础 5.5-6.5 分的学生。他们提升难度较高，需要大量练习和细致点评，同时英语基础较弱，需要中文辅助理解反馈内容，倾向于使用国产 AI 工具。因此选取他们为目标用户。

二、评测方法论

2.1 评测设计

2.1.1 测试材料

选取剑桥雅思 14 真题中的两篇学生作文（Task 1 流程图描述 + Task 2 议论文），分数段约 5.5，附考官原始评语作为金标准。

2.1.2 标准化 Prompt

Task 1 Prompt: 你是一名资深雅思写作考官。以下是一篇雅思 Task 1 小作文，请从 Task Achievement、Coherence & Cohesion、Lexical Resource、Grammatical Range & Accuracy 四个维度给出详细反馈。要求：1）指出具体问题并引用原文对应句子；2）给出修改示范；3）评估分数段。学生英语水平约为 band 5.5，请用该水平学生能理解的语言。注意：Task 1 要求客观描述数据/图表/流程，不需要给出个人观点。

Task 2 Prompt: 你是一名资深雅思写作教师。以下是一篇雅思 Task 2 作文，请从 Task Response、Coherence & Cohesion、Lexical Resource、Grammatical Range & Accuracy 四个维度给出详细反馈。要求：1）指出具体问题并引用原文对应句子；2）给出修改示范；3）评估分数段。学生英语水平约为 band 5.5，请用该水平学生能理解的语言。

Prompt 设计依据: 评判标准参考雅思 BC 官方写作评分标准。关于是否给大模型设定专家人设，参考论文 Expert Personas Improve LLM Alignment but Damage Accuracy，该研究表明在写作、角色扮演等对齐任务中，专家人设能带来显著性能提升，但提示词不宜过长。同时参考论文 LLM-as-a-tutor in EFL Writing Education 中提出的结合写作评分量表的提示方法，将雅思四维评分标准融入 prompt 设计。

2.2 语料采集

模型分组	模型名称	语料文件数	总词数(约)	总字符数(约)
金标准	雅思考官	2	274	1,360
参照组	ChatGPT / Claude / Gemini	6	3,518	22,250
国产模型	DeepSeek / 豆包 / 通义千问	6	2,345	16,047

2.3 分析方法

（1）Python 基础统计

使用 Python 对语料进行 Markdown 清洗、编码统一，统计词数、句数、平均句长、字符数等基本指标。

（2）AntConc 语料分析

- ① **词频分析**：提取各模型高频实词，按功能分类（评估类/指令操作类/学生原文内容词），计算各类占比；分析考官词汇重叠度
- ② **索引行分析**：搜索修改示范、原文引用、举例说明三类关键模式词，量化各模型的反馈策略差异
- ③ **N-gram 词组分析**：提取二元/三元高频词组，对比学生原文复述程度和考官专属评估搭配的使用情况
- ④ **词汇丰富度分析**：计算 TTR（类符/形符比）和 Guiraud 指数，评估各模型反馈语言的多样性

（3）雅思考官人工评估

从反馈准确性、建议可执行性、语言可理解性、反馈优先级四个维度，对 14 篇模型输出逐一打分（1-5 分）。

三、模型反馈能力对比

3.1 基础统计对比

各模型输出篇幅差异显著。ChatGPT 总词数最高（约 2,014 词），是考官（274 词）的 7.3 倍；Claude 最精炼（849 词）。篇幅差异本身不代表质量高低，和每个模型的设定风格有关，需结合后续分析判断。

指标	考官	ChatGPT	Claude	Gemini	DeepSeek	豆包	通义千问
总词数	252	2,175	948	694	1,179	798	761
不同词数	137	731	476	396	581	344	411
TTR	0.54	0.34	0.50	0.57	0.49	0.43	0.54
Guiraud 指数	8.63	15.67	15.46	15.03	16.92	12.18	14.90
句数	17	190	62	114	102	72	87
平均句长	14.8	11.4	15.3	6.1	11.6	11.1	8.7

3.2 反馈功能词分布

指标	考官	ChatGPT	Claude	Gemini	DeepSeek	豆包	通义千问
Top50 总频次	50	9	7	11	10	13	7
评估类占比(%)	53	3.3	9.8	23.9	10.9	17.3	7.1
指令/操作类占比(%)	0	10.5	9.1	18.8	14.8	22.8	16.5
内容词占比(%)	13.3	86.2	81.2	57.3	74.3	59.9	76.3
反馈信息密度	95.99%	73.04%	73.62%	79.54%	77.62%	74.26%	73.32%

“Top50 总频次”表示这个模型高频词表前 50 个词的出现次数加总，主要反映输出量的大小。此处将各模型 Top50 高频实词按功能分为三类：

- （1）评估类：是指用来做质量判断的词，比如考官常用的 **adequate**、**clear**、**errors**、**spelling**、**cohesion**、**accuracy** 这类。这类词占比越高，说明模型相对于提出修改方案而言，侧重评价作文质量。
- （2）指令操作类是给学生具体操作指引的词，主要是中文的“修改示范”“原文”“应为”“建议”“纠正”这些。这类词占比越高，说明模型越侧重提出修改方法。
- （3）学生原文内容词，值得是 **music**、**water**、**turbines**、**reservoir** 这些来自学生作文原文的词。占比越高，说明模型在反馈里大量复述了学生写的内容。

同时，反馈信息密度 = （总词数 - 内容词频次）÷ 总词数。

分析发现，考官评估类词占比 53%，内容词仅 13.3%；ChatGPT 反过来，内容词占比 86.2%，评估类仅 3.3%。反馈信息密度数据中，考官最高（95.9%），几乎不复述原文；ChatGPT 最低（73.0%），大量篇幅复述学生原文。国产模型中豆包（82.1%）和通义千问表现尚可。

3.3 考官词汇重叠度

指标	考官	ChatGPT	Claude	Gemini	DeepSeek	豆包	通义千问
重叠词数(Top50)	50	9	7	11	10	13	7

豆包重叠最多（13个），但重叠词多为 better、different、example 等通用词。考官特有的专业评估词（adequate、spelling、punctuation、cohesive）几乎没有任何模型使用。

3.4 反馈结构模式对比

功能分组	搜索关键词	参照组	参照组	参照组	国产模型	国产模型	国产模型	总计
		ChatGPT	Claude	Gemini	DeepSeek	豆包	通义千问	
修改示范类	修改示范	15	3	4	7	0	4	33
修改示范类	应为	2	1	3	4	0	7	17
修改示范类	应改为	0	0	4	0	0	0	4
修改示范类	instead of	0	0	0	0	0	0	0
	修改示范类小计	17	4	11	11	0	11	54
原文引用类	原文	0	1	0	5	25	6	37
原文引用类	原句	12	0	0	0	0	0	12
原文引用类	you wrote	0	0	0	0	0	0	0
原文引用类	in your essay	0	0	0	0	0	0	0
	原文引用类小计	12	1	0	5	25	6	49
举例说明类	for example	5	0	1	4	1	2	13
举例说明类	such as	0	0	0	0	0	0	0
举例说明类	比如	10	1	2	0	0	0	13
举例说明类	例如	1	0	0	1	0	0	2
	举例说明类小计	16	1	3	5	1	2	28
	总计	45	6	14	21	26	19	131

模型	反馈组织模式	核心标记词	风格定位
ChatGPT	原句→修改示范+比如举例	原句(12) 修改示范(15) 比如(10)	解释教学型
Claude	问题一/二/三 结构化分类	问题一(7) 问题二(7) 问题三(5)	结构分析型
Gemini	原文引用→纠正→评价	原文引用(12) 纠正(8) 评价(8)	评价纠错型
DeepSeek	问题+修改示范+建议	问题(13) 修改示范(7) 建议(8)	综合反馈型
豆包	原文→修改 逐条对照	原文(25) 修改(24)	逐条纠错型
通义千问	问题+应为+修改示范	问题(12) 应为(7) 修改示范(4)	纠错改写型

3.5 词汇丰富度对比

分组		金标准	参照组	参照组	参照组	国产模型	国产模型	国产模型
指标	说明	考官	ChatGPT	Claude	Gemini	DeepSeek	豆包	通义千问
总词数(tokens)	语料中所有词的数量	252	2175	948	694	1179	798	761
不同词数(types)	去重后的词形数量	137	731	476	396	581	344	411
TTR(类符/形符比)	不同词数÷总词数，越高=用词越丰富	0.5437	0.3361	0.5021	0.5706	0.4928	0.4311	0.5401
Root TTR(Guiraud指数)	不同词数÷√总词数，消除篇幅影响	8.63	15.67	15.46	15.03	16.92	12.18	14.9
句数	语料中的句子总数	17	190	62	114	102	72	87
平均句长(词/句)	总词数÷句数	14.8	11.4	15.3	6.1	11.6	11.1	8.7

TTR（类符/形符比）：Gemini 最高（0.57），豆包最低（0.43）。豆包的逐条对照模式导致大量

重复引用，拉低了用词多样性。消除篇幅影响的 Guiraud 指数：DeepSeek 最高（16.92），说明其在保持合理篇幅的同时用词最丰富。

3.6 索引行分析

功能分组	ChatGPT	Claude	Gemini	DeepSeek	豆包	通义千问
修改示范类小计	17	4	11	11	0	11
原文引用类小计	12	1	0	5	25	6
举例说明类小计	16	1	3	5	1	2
总计	45	6	14	21	26	19

3.7 四维反馈覆盖度

评分维度	考官	ChatGPT	Claude	Gemini	DeepSeek	豆包	通义千问
Task Response	52	876	622	401	810	254	548
Coherence & Cohesion	65	872	396	229	521	455	258
Lexical Resource	55	650	323	220	440	300	335
GRA	48	780	380	435	652	525	364
总字数	220	3178	1721	1285	2423	1534	1505
均衡度	0.74	0.74	0.52	0.51	0.54	0.48	0.47

所有模型都覆盖了全部四个评分维度，覆盖度本身没有区分度。

几个模型的回答差异主要在篇幅分配，ChatGPT 和 DeepSeek 总字数最高但分配不均，豆包在 TR 上只有 254 字但 GRA 有 525 字，说明它更擅长语法纠错但对任务分析较弱。

同时，几乎所有模型都偏重 GRA（语法纠错），因为语法错误最容易检测，但语法纠错用户可以使用如 Grammarly 等的专门的语法纠错软件，担任雅思写作老师的身份的 ai 的真正价值在于 TR 和 CC 维度的深度分析，而在国产模型在这两方面恰恰很薄弱。

均衡度=最少维度字数÷最多维度字数，越接近 1 说明四个维度的反馈越均衡。

3.8 N-gram 词组分析

通过分析每个模型回答的二元和三元词组，发现 AI 模型在词组层面和考官的语言完全不重叠。考官专属评估搭配（cohesive devices、overall progression、generally adequate、key features、clear overall progression）在所有六个 AI 模型中均为 0 命中。模型倾向于大量复述学生原文词组，而考官使用独立的专业评估语言。

词组类别	二元/三元词组	参照组	参照组	参照组	国产模型	国产模型	国产模型
		ChatGPT	Claude	Gemini	DeepSeek	豆包	通义千问
学生原文复述	feel better	6	8	2	6	6	3
学生原文复述	level reservoir	13	8	3	6	3	4
学生原文复述	power station	10	0	3	6	7	5
学生原文复述	reversible turbines	9	7	3	6	4	5
学生原文复述	use music	8	0	0	3	5	0
学生原文复述	water flowing force	3	2	0	2	2	0
学生原文复述	different cultures	8	2	0	0	3	0
考官专属评估搭配	cohesive devices	0	0	0	0	0	0
考官专属评估搭配	overall progression	0	0	0	0	0	0
考官专属评估搭配	generally adequate	0	0	0	0	0	0
考官专属评估搭配	key features	0	0	0	0	0	0
考官专属评估搭配	clear overall progression*	0	0	0	0	0	0
模型结构模板	约分 问题一 (Claude)	0	4	0	0	0	0
模型结构模板	问题 原文 修改 (豆包)	0	0	0	0	4	0
模型结构模板	cite start 原文引用 (Gemini)	0	0	3	0	0	0
模型结构模板	目前约分 问题 (DeepSeek)	0	0	0	4	0	0
学生原文复述词组合计		57	27	11	29	30	17

3.9 人工评估

本测评邀请两位雅思前考官，基于对 14 篇模型输出的逐一阅读，从反馈准确性、建议可执行性、语言可理解性、反馈优先级四个维度进行 1-5 分打分。

模型	反馈准确性	建议可执行性	语言可理解性	反馈优先级	总均分
ChatGPT	4.0	5.0	4.5	4.0	4.4
Claude	4.5	4.0	3.0	4.0	3.9
Gemini	4.0	4.0	4.0	3.0	3.8
DeepSeek	4.0	5.0	4.0	4.5	4.4
豆包	3.5	4.0	3.0	3.0	3.4
通义千问	4.0	4.0	4.0	3.0	3.8

ChatGPT 和 DeepSeek 并列最高（4.4 分）。ChatGPT 的优势在于建议可执行性（每个错误都附带详细修改示范和替换表达）和语言可理解性（中英文混合自然，用词贴近学生水平）。DeepSeek 的优势在于建议可执行性同样出色，且反馈优先级最清晰（Task 2 中明确告诉学生「先改什么能提分最快」）。

Claude 准确性最高（4.5 分），错误识别最精准，但语言可理解性偏低（3.0 分）——反馈偏技术化，中文辅助不足，对 5.5 水平学生来说阅读门槛较高。

豆包总分最低（3.4 分），主要短板在准确性（Task 2 有可疑误判）、可理解性（密集的原文→修改对照格式反而增加阅读负担）和优先级（未区分问题的重要程度）。

四、核心发现

发现 1：国产模型评估语言缺失

考官评估类词占比 53%，国产模型均低于 20%。考官专属评估搭配（cohesive devices、overall progression、generally adequate）在所有 AI 模型的 N-gram 分析中均为 0 命中。可见 AI 模型的反馈语言体系与考官存在根本性差距。

这一差距不仅是词频层面的。从 N-gram 数据看，考官的专业搭配（cohesive devices、overall progression、generally adequate、key features、clear overall progression）在六个 AI 模型中同样为 0 命中，没有任何一个模型哪怕使用过一次。这意味着 AI 模型在评估话语体系上和考官完全脱节。由于和雅思官方评分体系没有交集，评分的准确性和建议的质量也有待考证。

从词汇重叠的质量看，豆包虽然重叠词数最多（13 个），但拆开看，重叠词几乎全是 better、different、example、people、task 这类高频通用词。而考官 Top50 中真正有区分度的专业评估词，如 adequate、capitalisation、spelling、punctuation、cohesive 等，没有被任何模型纳入高频词表。可见国产大模型的回答虽然有和考官评语重叠的内容，但都是没有信息量的词。

发现 2：反馈策略显著分化

索引行数据细致地揭示了大模型的反馈策略差异。

标准化模型中，ChatGPT 的反馈策略偏向给出修改示范并举例说明。它的回答中修改示范类标记词出现 17 次，举例说明类 16 次，但原文引用类高达 12 次（全部来自“原句”一词），说明它在引用学生原文时偏好完整引述原句。Claude 则几乎不做原文引用（仅 1 次），也很少举例（1 次），而是靠结构化的问题编号来组织反馈，可见它的反馈精准简洁，但缺乏具体语境的说明。

国产模型中，豆包的原文引用类高达 25 次，远超其他所有模型，但修改示范类为 0，可见它大量引用了学生原文却不提供对应的修改范例，这在实际使用中意味着学生知道自己哪里错了，但不知道该怎么改。DeepSeek 则相对均衡，修改示范 11 次、原文引用 5 次、举例 5 次，三类功能都有涉及。通义千问的修改示范最多（11 次），但举例说明仅 2 次，反馈风格偏重告知学生具体的病句怎么改，而不是教会学生怎么写一个好的句子。

同时，所有模型都没有使用英文标记词，如 instead of、you wrote、in your essay、such as 的使用均为 0，说明即使在英语写作反馈的场景下，模型也完全依赖中文元语言来组织反馈结构。这对于想要通过批改过程顺带提升英语输入量的学生来说，是一个隐性损失。

发现 3：反馈效率差异悬殊

从回答的信息密度看，ChatGPT 内容词占比 86.2%，反馈信息密度仅 73%，大量篇幅复述学生原文。相比之下，考官信息密度 95.9%，用最少的篇幅传递最精准的评价。豆包 TTR 最低（0.43），

用词重复度最高。

从词汇丰富度看，ChatGPT 的 TTR 仅 0.34，是所有模型中最低的，甚至低于豆包（0.43）。但 ChatGPT 的内容词占比 86.2%，回答字符数也是最多的，怎么反而用词最不丰富？原因在于 TTR 受篇幅影响极大。篇幅越长，重复用词的概率越高，TTR 自然下降。这也是为什么需要看消除篇幅影响的 Guiraud 指数。Guiraud 指数下，DeepSeek 最高（16.92），说明它在控制住篇幅的前提下用词最丰富；豆包最低（12.18），可见他的反馈方式偏向大量的格式性重复用词。

从平均句长看，Gemini 平均句长仅 6.1 词/句，反馈极度碎片化，接近短语罗列；而 Claude 平均 15.3 词/句，接近考官的 14.8 词/句，反馈的完整度和可读性更高。国产模型中 DeepSeek（11.6）和豆包（11.1）居中，通义千问（8.7）偏短，反馈倾向于碎片化表达。

发现 4：回答质量

人工评估和语料分析的交叉验证揭示了一些有意思的错位。Claude 在准确性上得分最高（4.5），语料分析也显示它的反馈信息密度高、结构清晰，但语言可理解性仅 3.0 分，这它虽然回答得好，但并不一定能让学生能看懂。对于目标用户（5.5 分段学生）而言，Claude 的技术化反馈实际上增加了理解成本。ChatGPT 的准确性（4.0）不如 Claude，但建议可执行性（5.0）和语言可理解性（4.5）领先，结合其大量的举例说明（16 次）和修改示范（17 次），可以理解为它用“讲得多、讲得细”弥补了精确度上的差距。

国产模型中，DeepSeek 是唯一在反馈优先级维度上领先的模型（4.5 分），甚至高于 ChatGPT（4.0）。它在 Task 2 的反馈中明确告诉学生先改什么最能提分，这一点对于备考效率至关重要，大部分学生的痛点不是不知道哪里有错，而是不知道先改哪个错才能提高分数。豆包在四个维度上都没有亮点，尤其是准确性（3.5）和可理解性（3.0），前者说明存在误判风险，后者说明其密集的逐条对照格式并没有如预期般降低阅读门槛，反而造成了信息过载。国内外模型的核心差距在语言可理解性和反馈优先级上。

五、国产模型能力短板与产品机会点

能力短板	数据支撑	产品机会点
评估语言专业度不足	国产模型评估类词占比均<20%； 考官专属搭配 0 命中	引入雅思四维评分框架作为反馈模板，强制输出各维度专业评估
反馈角色未分离	所有模型同时纠错+评分+教学，信息过载	设计多模式切换：快速纠错/深度教学/模拟考官
反馈格式标准化不足	纠错标记词不统一（应为/应改为/原文/原句）	统一输出格式：错误定位→错误类型→修改示范→解释
语言可理解性不足	豆包、Claude 可理解性仅 3.0 分	关键术语自动附中文解释，反馈语言适配目标分数段
反馈优先级缺失	豆包、Gemini、通义优先级仅 3.0 分	增加最影响分数的 Top3 问题摘要模块

1、评估语言专业度不足

这里指的是大模型的反馈的底层框架普遍与雅思评分体系脱钩。考官的评估语言（adequate control、cohesive devices、clear progression）直接映射雅思官方 Band Descriptors 中的评分标准原文，学生反复接触这些表达后，能在考试中反向理解考官的评分逻辑。AI 模型用自己的语言体系替代了这一层，等于切断了从评分反馈反向学习、提升写作能力的学习链路。因此，产品机会点不仅在于引入专业术语，更在于将 Band Descriptors 的原文表述嵌入反馈模板，让学生在每次批改中自然习得考官的评判语言。

2、反馈角色未分离

数据显示，所有模型在单次输出中同时执行纠错（修改示范类标记词）、评估（评估类词汇）和教学（举例说明类标记词）三种功能，但各功能的比例完全不可控。ChatGPT 偏重教学（举例 16 次），豆包偏重纠错（原文引用 25 次），但用户无法根据自己的需求切换。实际使用场景中，考前冲刺的学生需要快速纠错模式（类似豆包的逐条对照），深度学习阶段的学生需要教学模式（类似 ChatGPT 的举例说明），而模考练习时需要模拟考官模式（类似考官的简洁评估风格）。多模式切换的产品价值在于把现有模型的不同优势变成可选项，而非让用户被动接受某一种固定风格。

3、反馈格式标准化不足

索引行分析中，同样是指出学生的问题句进行修正，不同模型使用了“应为”“应改为”“修改示范”“instead of”四种不同的标记词，甚至同一模型内部也不统一。这种不一致直接影响用户形成稳定的阅读习惯，用户每次都要重新适应反馈格式，注意力就无法完全集中在内容本身。统一格式的设计可以参考索引行数据中出现频率最高的模式：错误定位（引用原文）→ 错误类型（语法/词汇/逻辑）→ 修改示范 → 解释说明，这一流程综合了 ChatGPT 的教学性和豆包的具体性。

4、语言可理解性不足

人工评估中，豆包和 Claude 都只拿到 3.0 分。但两者的原因不同，Claude 的问题是反馈语言过于

技术化、中文辅助不足，学生读不懂英文评语；豆包的问题是格式导致的认知过载，25 次原文引用配合 24 次修改标注，密集的“原文→修改”对照在视觉上造成信息轰炸，学生反而抓不住重点。因此，可理解性的优化方案也应分两条路，对技术化反馈增加中文注释和术语解释，对密集纠错反馈增加视觉层次（高亮、折叠、优先级标签）来降低认知负荷。

5、反馈优先级缺失

四维反馈覆盖度数据显示，国产模型普遍在 GRA 维度投入最多篇幅（豆包 525 字、DeepSeek 652 字），而在 TR 维度投入最少（豆包 254 字、通义千问 548 字）。这种偏重语法纠错的倾向恰恰与提分优先级相反。对于 5.5 分段学生，TR 和 CC 维度的改善对总分的拉动作用远大于 GRA。因为语法错误可以用 Grammarly 等专用工具高效解决，而任务回应是否切题、论证逻辑是否清晰，这些才是需要老师去判断的问题。“Top3 问题摘要”模块的设计核心不只是标出优先级，而是要把资源从 GRA 向 TR 和 CC 倾斜，引导学生关注真正决定分数的维度。

六、产品方案设计

基于以上五项核心发现，设计了 AI 雅思写作批改产品的核心功能原型，包含 5 个页面。每个设计决策均有语料分析数据支撑。

在线交互原型：<https://yuhanwang323-hub.github.io/ielts-ai-prototype>

6.1 功能架构

核心功能包含：作文提交（选择题型+目标分数段+反馈模式）→ 反馈总览（四维评分+Top3 问题摘要）→ 详细反馈（快速纠错模式/深度教学模式）→ 语言设置（中文/英文/中英对照）。

6.2 核心页面说明

页面 1：作文提交页

功能：上传/粘贴作文 + 选择题目类型(Task1/Task2) + 选择目标分数段 + 选择反馈模式（快速纠错/深度教学/模拟考官）。反馈模式切换基于发现 2：所有模型反馈角色未分离。

页面 2：反馈主页面

功能：四维评分可视化 + 总分预估 + 最影响分数的 Top3 问题摘要 + 切换详细反馈。Top3 摘要模块基于发现 4：国产模型反馈优先级缺失。

页面 3：详细反馈页（快速纠错模式）

功能：左栏原文错误句高亮标注，右栏对应修改示范+错误类型标签+三级优先级标记。参考豆包的逐条对照模式（原文引用 25 次，为所有模型最高），但增加了优先级标记和错误类型分类，解决豆包无优先级和格式不统一的问题。

页面 4：详细反馈页（深度教学模式）

功能：按问题分类展示，每个问题附完整教学链：原文引用→错误分析→修改示范→举例说明→练习建议。融合 ChatGPT 的举例教学策略（举例说明类标记词 16 次，为所有模型最高）。

页面 5：反馈语言设置

功能：可切换反馈语言为中文/英文/中英对照，专业术语自动附中文解释，雅思评分标准原文高亮。基于人工评估发现：语言可理解性是国产模型的核心短板之一。

七、预期效果与迭代方向

7.1 预期效果

反馈具体性提升：通过统一反馈格式和引入专业评估术语，减少笼统反馈占比。用户理解效率提升：多模式切换让不同需求的用户获得匹配的反馈深度。二次修改率提升：修改示范+举例说明降低学生理解和执行门槛。反馈优先级清晰化：Top3 问题摘要帮助学生聚焦最能提分的改进点。

7.2 后续迭代方向

扩大语料规模：增加更多分数段（4.5/5.0/6.0/7.0）的学生作文样本。增加题型覆盖：加入 Task 1 其他类型（表格、柱状图、地图题）。用户测试验证：邀请目标用户实际使用原型，收集反馈迭代设计。追踪模型更新：各模型持续迭代，定期复测评估能力变化。增加评分者：邀请更多评估者参与人工评估，计算评分者间一致性，提高结论可靠性。

附录

人工评估评分标准

维度	1 分	2 分	3 分	4 分	5 分
反馈准确性	多处误判	2-3 处明显误判	偶有误判但大部分准确	仅 1 处小误判	全部准确
建议可执行性	只说需要改进	给方向无示范	部分修改示范	大部分附带示范	每个问题都有示范
语言可理解性	全英文大量术语	英文为主中文不足	中英混合基本能懂	术语有解释	完全适配学生水平
反馈优先级	问题无序罗列	有顺序但不明确	按维度分组	指出最关键问题	有优先级+提分建议